


Modelowanie PD w Kredytach Konsumenckich

Antoni Ballaun
Laura Hoang
Jędrzej Joniec
Piotr Zambrzycki




Opis projektu



Opis danych

- Oryginalnie **81 zmiennych**.
- Oryginalnie **113 tys. Obserwacji**.
- Proporcje danych – **85.2% nie-default** i **14.8% default**.
- Target: **Defaulted**, na podstawie **LoanStatus**: Past Due ponad 90 dni.



Wstępna preparacja danych



- **Usunięcie 18 kolumn** (ponad 20% braków danych).
- **Usunięcie wierszy z brakami danych** w wybranych 9 kolumnach (zawierających poniżej 1000 braków).
- **Imputacja pozostałych braków** za pomocą statystyk ze zmiennych.
- Podział danych: zbiór **treningowy 80%** i **testowy 20%**.

Binning zmiennych

- Binning przeprowadzony z wykorzystaniem biblioteki **optbinning**.
- Wykorzystanie techniki optymalizacyjnej **constrained programming**.
- **Optymalizacja pod kątem Information Value**, przy zachowaniu ograniczeń do trzech przedziałów.
- Algorytm dopasowany na zbiorze treningowym. Dane treningowe i testowe przetransformowane na **WoE**.

Selekcja zmiennych


- Odrzucenie na podstawie $IV < 0.1$.
- Odrzucenie na podstawie Regresji Logistycznej z karą L1 (**Lasso Regression**), wyeliminowane zmienne których **współczynniki zostały wyzerowane**.
- Po selekcji: **20** zmiennych objaśniających.



Regresja Logistyczna

- Model dopasowany na danych przetransformowanych **WoE**


Threshold = 0.60	
Accuracy	0.79
AUC	0.83
Gini	0.6548
Precision	0.38
F1	0.48
Recall	0.64



Las losowy

- **Model:** Random Forest z 100 drzewami (głębokość nieograniczona)
- **Budowa drzew:** każde drzewo trenowane na bootstrapowanej próbce danych
- **Rozgałęzienia:** losowy wybór podzbioru cech przy każdym podziale
- **Agregacja:** predykcja przez głosowanie większościowe
- **Uczenie:** z użyciem wag klas proporcjonalnych do liczby obserwacji

Threshold = 0.55	
Accuracy	0.75
AUC	0.83
Gini	0.66
Precision	0.64
Recall	0.37
F1	0.48




Model XGB

- Najlepsze wyniki z **nałożeniem wag** na klasy proporcjonalnych do ilości obserwacji.
- **Grid search** w celu znalezienia optymalnych hiperparametrów

Threshold = 0.55

Accuracy	0.78
AUC	0.86
Gini	0.71
Precision	0.38
Recall	0.74
F1	0.50




Sieć Neuronowa

Architektura:

- Wejście: kategoryczne (+**embedding**) i numeryczne
 - Warstwa gęsta: **64** neuronów, **ReLU**
 - Warstwa gęsta: **32** neurony, **ReLU**
 - Wyjście: 1 neuron, sigmoid
- + **class weight** przy uczeniu

Threshold = 0.65	
Accuracy	0.82
AUC	0.84
Gini	0.68
Precision	0.42
Recall	0.60
F1	0.69



Scoring Modeli

	<i>Threshold</i>	<i>Accuracy</i>	<i>Gini</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>
Logistic Regression	0.60	0.79	0.65	0.38	0.64	0.48
Random Forest	0.55	0.75	0.66	0.37	0.67	0.48
XGboost	0.55	0.78	0.71	0.38	0.74	0.50
Neural Network	0.65	0.82	0.68	0.42	0.60	0.49

Symulacja Wyniku Finansowego

Założenia:

- Średnia kwota pożyczki: \$8.000
- Średnie oprocentowanie: 18% lub 13%


	TP	FP	TN	FN
Log Reg	2 600	5 213	14 340	808
Random Forest	2 286	3 847	15 706	1 122
XGBoost	2 528	4 190	15 363	880
Neural Network	1 811	2 169	17 384	1 597

3 scenariusze dla **LGD**:


Good = 0.5 **Medium** = 0.7 **Bad** = 0.9

Zarobki netto = **TN** (*zysk*) – **FP** (*utracony zysk*) – **FN** (*strata*)

Wyniki Symulacji (0.18)



Wyniki Symulacji (0.13)



Dziękujemy za uwagę!

